Bài tập lớn KPDL nhóm 8 - Bài báo cáo KPDL

Khai phá dữ liệu nâng cao (Đại học Thủy lợi)

Scan to open on Studeersnel

Studocu is not sponsored or endorsed by any college or university
Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

TRƯỜNG ĐẠI HỌC THỦY LỢI

KHOA CÔNG NGHỆ THÔNG TIN

BÀI TẬP LỚN

HỌC PHẦN: KHAI PHÁ DỮ LIỆU

ĐỀ TÀI: PHÂN CỤM ĐẶC TRƯNG CẢM XÚC TRONG GIỌNG NÓI NHẰM HỖ TRỢ HỆ THỐNG PHẢN HỒI TỰ ĐỘNG KHÁCH SỬ DỤNG

Nhóm sinh viên thực hiện: Nhóm 8

Nguyễn Tuấn Hiệp	2251161996
Hoàng Anh Khoa	2251162045
Trần Văn Chiến	2251161958
Bùi Hoàng Dương	2151061178
Vi Hoàng Trung	2251162192
Đặng Quỳnh Vy	2251162213

Giảng viên hướng dẫn: Lê Thị Tú Kiên

Hà Nội, năm 2025

Dit document is beschikbaar op studeersnel

Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

BẢNG PHÂN CÔNG NHIỆM VỤ

Tên thành viên	Nhiệm vụ	Điểm số
Nguyễn Tuấn Hiệp (Nhóm trưởng)	Tìm hiểu và xây dựng thuật toán K-means để phân cụm dữ liệu âm thanh	
Hoàng Anh Khoa	Tìm hiểu và làm docs về thuật toán K-means để phân cụm dữ liệu âm thanh	
Trần Văn Chiến	Tìm hiểu thuật toán, làm docs và thực hiện thuật toán Gaussian Mixture Model (GMM) để phân cụm dữ liệu âm thanh	
Bùi Hoàng Dương	Tìm hiểu thuật toán Gaussian Mixture Model (GMM)	
Vi Hoàng Trung	Tiền xử lí dữ liệu âm thanh để phân cụm theo cảm xúc	
Đặng Quỳnh Vy	Tiền xử lí dữ liệu âm thanh để phân cụm theo cảm xúc	

Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

MỤC LỤC

MỞ ĐẦU.....5
CHƯƠNG 1: TỔNG QUAN VỀ KHAI PHÁ DỮ LIỆU.....6
1. Lý do chọn đề tài..... 6
2. Mô tả bài toán phân cụm đặc trưng cảm xúc trong giọng nói..... 6
a. Tổng quan bài toán..... 6
b. Quy trình thực hiện.....7
CHƯƠNG 2: TIỀN XỬ LÝ DỮ LIỆU..... 8
1. Tóm tắt mô tả về dữ liệu.....8
2. Làm sạch dữ liệu.....10
a. Xử lý dữ liệu thiếu.....10
b. Xử lý dữ liệu ngoại lai.....11
c. Tích hợp dữ liệu (Data Integration).....12
d. Biến đổi dữ liệu (Data Transformation)..... 12
e. Thu giảm dữ liệu (Data Reduction).....13
CHƯƠNG 3: THUẬT TOÁN K-MEANS.....16
1. Giới thiệu chung..... 16
1.1. Khái niệm..... 16
1.2. Nguyên lý hoạt động..... 16
2. Triển khai K-mean trong code.....17
2.1. Tiền xử lý dữ liệu..... 17
2.2. Giảm chiều bằng PCA.....17
2.4. Áp dụng K-mean..... 19
2.7. Đánh giá và trực quan hóa.....21
2.8. Kết quả và Đánh giá.....22
3. So sánh với các thuật toán khác.....23
4. Ứng dụng của K-mean.....24
5. Ý nghĩa thực tiễn..... 24
6. Lý do lựa chọn K-mean.....25
CHƯƠNG 4: GAUSSIAN MIXTURE MODEL.....26
1. Mở đầu.....26
1.1. Bối cảnh.....26
1.2. Mục tiêu.....26

Dit document is beschikbaar op studeersnel
Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

1.3. Phương pháp....26
2. Lý thuyết Gaussian Mixture Model....26
2.1. Định nghĩa....26
2.2. Công thức và các bước thực hiện thuật toán....27
2.3. Ưu điểm....28
2.4. Nhược điểm....28
3. Triển khai thuật toán GMM....29
3.1. Chuẩn bị dữ liệu....29
3.2. Tối ưu số cụm....29
3.3. Xây dựng mô hình GMM....29
3.4. Mã nguồn triển khai....30
4. Kết quả và đánh giá....30
4.1. Kết quả phân cụm....30
4.2. Trực quan hóa....32
4.3. Đánh giá....32
4.4. Ứng dụng....33
5. Nhận xét, kết luận và hướng phát triển....33
5.1. Nhận xét....33
5.2. Kết luận....34
5.3. Hướng phát triển....34
6. Tài liệu tham khảo....35
CHƯƠNG 5: KẾT LUẬN....36
LỜI CẢM ƠN....37

Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

MỞ ĐẦU

Trong thời đại số hóa hiện nay, các hệ thống chăm sóc khách hàng tự động như chatbot, trợ lý ảo hay tổng đài thông minh ngày càng đóng vai trò quan trọng trong việc tương tác giữa doanh nghiệp và người dùng. Tuy nhiên, phần lớn các hệ thống này mới chỉ xử lý nội dung dựa trên ngữ nghĩa văn bản hoặc cú pháp câu nói, mà chưa khai thác đầy đủ những tín hiệu cảm xúc ẩn chứa trong giọng nói của người dùng. Cảm xúc, đặc biệt trong giọng nói, là một yếu tố then chốt phản ánh mức độ hài lòng, bức xúc hay nhu cầu hỗ trợ khẩn cấp của khách hàng – nếu được phát hiện và xử lý kịp thời, sẽ nâng cao đáng kể hiệu quả và sự thân thiện của hệ thống.

Từ thực tiễn đó, bài toán phân cụm cảm xúc trong giọng nói trở nên thiết yếu, đặc biệt khi không có nhãn sẵn và cần phân loại các trạng thái cảm xúc khác nhau theo cách không giám sát (unsupervised). Trong khuôn khổ đề tài này, nhóm em đã lựa chọn hai thuật toán phân cụm ít phổ biến nhưng tiềm năng là Spectral Clustering và Self-Organizing Maps (SOM) để áp dụng lên các đặc trưng âm thanh trích xuất từ giọng nói, hướng tới xây dựng một mô hình nền hỗ trợ các hệ thống phản hồi tự động hiểu rõ hơn tâm trạng người dùng, từ đó điều chỉnh cách phản hồi phù hợp.

Trong bài báo cáo này chúng em sẽ trình bày chi tiết quy trình tiền xử lý dữ liệu giọng nói, trích xuất đặc trưng, mô hình hóa và đánh giá kết quả phân cụm, nhằm kiểm chứng tính hiệu quả của các phương pháp đề xuất trong việc nhóm các đặc trưng cảm xúc tương đồng lại với nhau.

Chúng em cũng xin cảm ơn cô Lê Thị Tú Kiên đã tận tình hướng dẫn và hỗ trợ chúng em hoàn thành bài tập lớn môn Khai phá dữ liệu.

Chúng em xin chân thành cảm ơn!

Dit document is beschikbaar op studeersnel

Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

CHƯƠNG 1: TỔNG QUAN VỀ KHAI PHÁ DỮ LIỆU

1. Lý do chọn đề tài

Trong thời đại công nghệ số, việc tương tác giữa con người và máy móc thông qua giọng nói đang trở nên phổ biến hơn bao giờ hết. Tuy nhiên, hầu hết các hệ thống phản hồi tự động hiện nay mới chỉ tập trung vào nội dung ngôn ngữ (tức *"nói cái gì"*) mà chưa chú trọng đến yếu tố cảm xúc (*"nói như thế nào"*). Trong khi đó, giọng nói là kênh truyền tải cảm xúc tự nhiên và trực tiếp nhất của con người, có thể phản ánh sự hài lòng, tức giận, lo lắng, hay buồn bã mà người dùng không thể hiện qua từ ngữ.

Khi một hệ thống phản hồi có khả năng nhận biết và phân tích cảm xúc trong giọng nói, nó sẽ tạo ra trải nghiệm giao tiếp thân thiện và hiệu quả hơn. Tuy nhiên, việc gán nhãn cảm xúc cho dữ liệu giọng nói thường tốn nhiều thời gian và nguồn lực, do đó bài toán phân cụm không giám sát (unsupervised clustering) trở thành một hướng đi khả thi để xử lý bài toán này một cách tự động.

2. Mô tả bài toán phân cụm đặc trưng cảm xúc trong giọng nói

a. Tổng quan bài toán

- Mô tả bài toán: Bài toán tập trung vào đặc trưng âm học (là các thông tin thể hiện âm sắc, tần số, cao độ, nhịp điệu và các đặc tính khác của giọng nói) nhằm tìm ra đặc trưng chung giữa các đoạn giọng nói để phân cụm chúng thành các nhóm có cảm xúc giống nhau – dù không có nhãn sẵn – nhằm hiểu được cấu trúc tiềm ẩn trong dữ liệu cảm xúc giọng nói, từ đó hỗ trợ cho các hệ thống phản hồi tự động hiểu rõ cảm xúc người dùng.
- Tập dữ liệu của bài toán bao gồm 7442 mẫu âm thanh WAV lấy được từ trên Kaggle, bao gồm có 5 loại đặc trưng âm học, cụ thể:
    - MFCC (Mel-Frequency Cepstral Coefficients): 13 đặc trưng, là một cách để biểu diễn âm thanh dưới dạng một chuỗi các con số, giúp máy tính có thể hiểu và xử lý âm thanh một cách hiệu quả.
    - Mel-Spectrogram: 128 đặc trưng, là một biểu diễn phổ tần số của tín hiệu âm thanh theo thời gian, được chuyển đổi sang thang tần số Mel, là thang đo gần với cảm nhận thính giác của con người.
    - Chroma Features: 12 đặc trưng, là một đặc trưng âm nhạc thể hiện mức độ hiện diện của 12 nốt nhạc cơ bản (C, C#, D, D#, ..., B) trong một đoạn âm thanh, bỏ qua quãng (octave).

Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

    - Zero-Crossing Rate (ZCR): 1 đặc trưng, là tốc độ mà tín hiệu âm thanh đổi dấu (từ dương sang âm hoặc ngược lại) trong một khoảng thời gian ngắn, dùng để đo xem tín hiệu dao động nhanh hay chậm – tức là nó giúp biết âm thanh "sắc, thô" hay "mượt, mềm".
    - Spectral Contrast: 7 đặc trưng, hay còn gọi là độ tương phản phổ, là một đặc trưng âm thanh đo sự chênh lệch năng lượng giữa các đỉnh (peak) và đáy (valley) trong từng dải tần số của tín hiệu.
- Nguồn dữ liệu: https://www.kaggle.com/datasets/ejlok1/cremad

b. Quy trình thực hiện

- Bước 1: Thu thập dữ liệu đầu vào là các mẫu âm thanh.
- Bước 2: Tiền xử lý, biến dữ liệu thô thành dạng số, làm sạch dữ liệu.
- Bước 3: Sử dụng các thuật toán phân cụm để khai phá dữ liệu.
- Bước 4: Kiểm tra hiệu quả mô hình đã xây dựng.
- Bước 5: Áp dụng mô hình vào các tình huống thực tế.
- Bước 6: Đánh giá và đưa ra kết luận dựa trên kết quả.

Dit document is beschikbaar op studeersnel
Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

CHƯƠNG 2: TIỀN XỬ LÝ DỮ LIỆU

1. Tóm tắt mô tả về dữ liệu

Tập dữ liệu được sử dụng trong chương trình là CREMA-D, được tải về từ Kaggle và được lưu trữ trong thư mục AudioWAV với các file âm thanh định dạng WAV. Dữ liệu bao gồm 7442 tập âm thanh, mỗi file đại diện cho một mẫu giọng nói chứa thông tin về cảm xúc và cường độ cảm xúc. Các đặc trưng được trích xuất từ file âm thanh.

Các đặc trưng và nhãn:

- Đặc trưng:
    - MFCC (Mel-Frequency Cepstral Coefficients): 13 hệ số trung bình, biểu thị đặc trưng tần số của âm thanh.
    - Mel-Spectrogram: 128 giá trị trung bình, biểu thị phổ tần số Mel.
    - Chroma Features: 12 giá trị trung bình, biểu thị đặc trưng âm sắc.
    - Zero-Crossing Rate (ZCR): 1 giá trị trung bình, biểu thị tần suất tín hiệu âm thanh đổi dấu.
    - Spectral Contrast: 7 giá trị trung bình, biểu thị sự khác biệt về cường độ trong các dải tần số.
    - Tổng cộng: 161 đặc trưng được trích xuất từ mỗi file âm thanh.
- Nhãn: Chỉ được sử dụng để đánh giá và trực quan hóa kết quả, không phải để huấn luyện mô hình phân cụm, **không dùng trực tiếp trong quá trình phân cụm**.
    - Cảm xúc (emotion): Gồm 6 loại: ANG (Anger - tức giận), DIS (Disgust - ghê tởm), FEA (Fear - sợ hãi), HAP (Happy - vui vẻ), NEU (Neutral - trung lập), SAD (Sad - buồn).
      Phân bố:
        - ANG (1271)
        - DIS (1271)
        - FEA (1271)
        - HAP (1271)
        - NEU (1087)
        - SAD (1271)
    - Cường độ (intensity): Gồm các mức: XX (6076), HI (455), LO (455), MD (455), X (1).

Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

Quy trình đọc và xử lý dữ liệu:

- Dữ liệu âm thanh được đọc từ các file WAV trong thư mục AudioWAV bằng thư viện librosa.
- Hàm extract_features trích xuất các đặc trưng (MFCC, Mel-Spectrogram, Chroma, ZCR, Spectral Contrast) từ mỗi file âm thanh.
- Tên file được phân tích để lấy nhãn cảm xúc và cường độ (ví dụ: tên file như 1001_DFA_ANG_XX.wav cho biết cảm xúc là ANG và cường độ là XX) (Dù nhãn cảm xúc và cường độ được trích xuất từ tên file, chúng không được sử dụng để hướng dẫn thuật toán phân cụm. Thay vào đó, thuật toán phân cụm chỉ dựa vào đặc trưng âm thanh để tự động tìm ra các nhóm tương đồng).
- Các đặc trưng được chuẩn hóa bằng StandardScaler và lưu vào file CSV (crema_d_features.csv) dưới dạng DataFrame với các cột đặc trưng, tên file, cảm xúc, và cường độ.

Mục tiêu bài toán:

- Bài toán phân cụm: Sử dụng các đặc trưng trích xuất từ âm thanh để phân cụm dữ liệu theo cảm xúc giọng nói, giúp phân tích và dự đoán cảm xúc dựa trên đặc trưng âm thanh.
- Phân tích dữ liệu bao gồm:
    - Thống kê phân bố cảm xúc và cường độ.
    - Trực quan hóa waveplot và Mel-Spectrogram cho từng cảm xúc.
    - Giảm chiều dữ liệu bằng PCA để trực quan hóa phân bố đặc trưng theo cảm xúc.

Lưu ý:

- Dữ liệu được tiền xử lý và lưu dưới dạng CSV để dễ dàng sử dụng cho các bước phân tích hoặc phân cụm tiếp theo.
- Các biểu đồ phân tích (phân bố cảm xúc, waveplot, spectrogram, PCA) được lưu vào thư mục AudioWAV để hỗ trợ việc đánh giá dữ liệu.

Dit document is beschikbaar op studeersnel
Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

2. Làm sạch dữ liệu

a. Xử lý dữ liệu thiếu

Trong tập dữ liệu CREMA-D, dữ liệu thiếu có thể xảy ra trong quá trình trích xuất đặc trưng âm thanh (MFCC, Mel-Spectrogram, Chroma, ZCR, Spectral Contrast) từ các file WAV do lỗi xử lý hoặc file âm thanh không hợp lệ. Cách xử lý như sau:

- Đặc trưng âm thanh (MFCC, Mel-Spectrogram, Chroma, ZCR, Spectral Contrast):
    - Trong hàm extract_features, nếu quá trình trích xuất đặc trưng thất bại (ví dụ: file âm thanh bị hỏng hoặc không thể đọc), hàm sẽ trả về None và in thông báo lỗi (print(f"Lỗi khi xử lý {file_path}: {e}")).
    - Trong hàm preprocess_data, các mẫu có đặc trưng trả về None sẽ bị loại bỏ khỏi danh sách đặc trưng (features_list) và không được thêm vào DataFrame. Điều này đảm bảo rằng chỉ các mẫu có đầy đủ 161 đặc trưng được giữ lại.

```
features = extract_features(file_path)
if features is not None:
    features_list.append(features)
    file_names.append(file_name)
    emotions.append(emotion)
    intensities.append(intensity)
```

    - Kết quả: Không có dữ liệu thiếu trong DataFrame cuối cùng, vì các mẫu lỗi đã được loại bỏ.
- Nhãn (emotion, intensity):
    - Nhãn cảm xúc và cường độ được trích xuất từ tên file (ví dụ: 1001_DFA_ANG_XX.wav → emotion = ANG, intensity = XX). Do tên file trong CREMA-D được định dạng chuẩn, không có trường hợp nhãn bị thiếu.
    - Nếu có file nào không tuân theo định dạng (ví dụ: thiếu phần cảm xúc hoặc cường độ), nó sẽ không được xử lý đúng và bị loại bỏ trong bước kiểm tra tên file.

Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

b. Xử lý dữ liệu ngoại lai

Ngoại lai là các giá trị đặc trưng âm thanh bất thường (ví dụ: giá trị MFCC hoặc Mel-Spectrogram quá lớn hoặc quá nhỏ do nhiễu âm thanh). Trong chương trình, tuy không có bước xử lý ngoại lai rõ ràng, các đặc trưng đã được chuẩn hóa bằng StandardScaler, giúp giảm ảnh hưởng của các giá trị bất thường. Để xử lý ngoại lai một cách đầy đủ, có thể áp dụng phương pháp IQR (Interquartile Range) cho các đặc trưng số như sau:

Cách thực hiện:

- Bước 1: Tính các giá trị thống kê:
    - Sắp xếp dữ liệu của từng đặc trưng số (ví dụ: mfcc_0, mel_0, zcr, v.v.) theo thứ tự tăng dần: {x_(1,j), x_(2,j), ..., x_(n,j)}.
    - Tính tứ phân vị thứ nhất (Q1): Giá trị tại vị trí 25% của dữ liệu đã sắp xếp, tức là Q1 = x_(n/4,j).
    - Tính tứ phân vị thứ ba (Q3): Giá trị tại vị trí 75% của dữ liệu đã sắp xếp, tức là Q3 = x_(3n/4,j).
    - Tính IQR: IQR = Q3 - Q1.
    - Xác định giới hạn dưới và trên:
        - Giới hạn dưới = Q1 - 1.5 × IQR
        - Giới hạn trên = Q3 + 1.5 × IQR
- Bước 2: Xử lý ngoại lai:
    - Với mỗi giá trị x_(i,j) trong đặc trưng số j:
        - Nếu x_(i,j) < Giới hạn dưới, thay x_(i,j) bằng Giới hạn dưới.
        - Nếu x_(i,j) > Giới hạn trên, thay x_(i,j) bằng Giới hạn trên.
        - Các giá trị trong khoảng [Giới hạn dưới, Giới hạn trên] được giữ nguyên.
- Lưu ý: Trong mã hiện tại, bước xử lý ngoại lai chưa được thực hiện. Để cải thiện, có thể thêm hàm xử lý ngoại lai trước khi chuẩn hóa dữ liệu bằng StandardScaler.

Dit document is beschikbaar op studeersnel

Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

c. Tích hợp dữ liệu (Data Integration)

- Mô tả: Tích hợp dữ liệu là quá trình kết hợp dữ liệu từ nhiều nguồn thành một tập dữ liệu thống nhất. Trong bài toán này, dữ liệu chỉ được lấy từ một nguồn duy nhất (thư mục ./AudioWAV chứa các file WAV của CREMA-D), do đó không cần thực hiện tích hợp lược đồ hay xử lý dư thừa giữa các nguồn.
- Xử lý:
    - Tất cả các file âm thanh được đọc từ thư mục AudioWAV bằng glob.
    - Các đặc trưng (MFCC, Mel-Spectrogram, Chroma, ZCR, Spectral Contrast) được trích xuất và kết hợp thành một mảng duy nhất cho mỗi mẫu (np.concatenate trong hàm extract_features).
    - Nhãn cảm xúc và cường độ được trích xuất từ tên file và lưu cùng đặc trưng trong DataFrame.

d. Biến đổi dữ liệu (Data Transformation)

Chuẩn hóa dữ liệu (Z-score):

- Tất cả các đặc trưng âm thanh (161 đặc trưng: 13 MFCC, 128 Mel-Spectrogram, 12 Chroma, 1 ZCR, 7 Spectral Contrast) được chuẩn hóa bằng phương pháp Z-score sử dụng StandardScaler từ sklearn.preprocessing.
- Công thức chuẩn hóa Z-score:
    - Tính trung bình:

$$\mu_j = \frac{1}{n} \sum_{i=1}^{n} x_{i,j}$$

Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

Trong đó:

- μ_j: Trung bình của đặc trưng j.
- $x_{i,j}$: Giá trị của đặc trưng j tại mẫu i.
- n: Số lượng mẫu.

○ Tính độ lệch chuẩn:

$$\sigma_j = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_{i,j} - \mu_j)^2}$$

○ Chuẩn hóa Z-score:

$$x'_{i,j} = \frac{x_{i,j} - \mu_j}{\sigma_j} \quad (\text{nếu } \sigma_j \neq 0)$$

○ Kết quả: Các đặc trưng được đưa về thang đo có trung bình bằng 0 và độ lệch chuẩn bằng 1, giúp giảm ảnh hưởng của các giá trị có thang đo khác nhau trong quá trình phân cụm.

Mã hóa: Không cần mã hóa các đặc trưng phân loại, vì tất cả đặc trưng âm thanh đều là số (liên tục). Nhãn cảm xúc (emotion) và cường độ (intensity) được giữ dưới dạng chuỗi (string) trong DataFrame để phục vụ phân tích và trực quan hóa, không cần mã hóa thành số vì đây là bài toán phân cụm (không sử dụng nhãn trong thuật toán).

e. Thu giảm dữ liệu (Data Reduction)

Giảm chiều bằng PCA:

- Trong hàm analyze_data, phương pháp PCA (Principal Component Analysis) được sử dụng để giảm số chiều của dữ liệu từ 161 đặc trưng xuống

Dit document is beschikbaar op studeersnel
Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

2 thành phần chính (PC1, PC2) để trực quan hóa phân bố đặc trưng theo cảm xúc.

- Cách thực hiện:
    - Loại bỏ các cột không phải đặc trưng (file_name, emotion, intensity) khỏi DataFrame.
    - Áp dụng PCA với n_components=2:

```
features = df.drop(['file_name', 'emotion', 'intensity'], axis=1)
pca = PCA(n_components=2)
features_2d = pca.fit_transform(features)
```

    - Tạo DataFrame mới (pca_df) với PC1, PC2 và nhãn emotion để vẽ scatter plot.
- Mục đích:
    - Giảm chiều giúp trực quan hóa dữ liệu trong không gian 2D, cho thấy sự phân tách giữa các cảm xúc dựa trên đặc trưng.
    - Trong bài toán phân cụm, PCA có thể được sử dụng để giảm số chiều trước khi áp dụng thuật toán phân cụm, giúp giảm chi phí tính toán và loại bỏ các đặc trưng ít quan trọng.

Loại bỏ đặc trưng dư thừa:

- Mã hiện tại chưa thực hiện loại bỏ đặc trưng dựa trên hệ số tương quan hoặc các phương pháp chọn lọc đặc trưng khác. Tuy nhiên, để cải thiện, có thể áp dụng phương pháp dựa trên hệ số tương quan hoặc các kỹ thuật như Recursive Feature Elimination (RFE) để chọn các đặc trưng quan trọng nhất cho phân cụm.

Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

- Công thức tính hệ số tương quan (nếu áp dụng):

$$r_j = \frac{\sum_{i=1}^{n}(x_{i,j} - \mu_j)(y_i - \mu_y)}{\sqrt{\sum_{i=1}^{n}(x_{i,j} - \mu_j)^2 \sum_{i=1}^{n}(y_i - \mu_y)^2}}$$

Trong đó:

- $x_{i,j}$: Giá trị đặc trưng j tại mẫu i.
- y_i: Nhãn cảm xúc (nếu cần đánh giá, phải mã hóa thành số).
- μ_j, μ_y: Trung bình của đặc trưng j và nhãn.
- Chọn các đặc trưng có $|r_j|$ lớn hơn một ngưỡng nhất định.

Kết luận

- Xử lý dữ liệu thiếu: Các mẫu lỗi (đặc trưng trả về None) được loại bỏ, đảm bảo không có dữ liệu thiếu trong DataFrame.
- Xử lý ngoại lai: Chưa được thực hiện rõ ràng, nhưng chuẩn hóa Z-score giúp giảm ảnh hưởng của ngoại lai. Có thể thêm phương pháp IQR để xử lý triệt để.
- Tích hợp dữ liệu: Không cần thiết do dữ liệu từ một nguồn duy nhất.
- Biến đổi dữ liệu: Chuẩn hóa Z-score được áp dụng để đưa đặc trưng về cùng thang đo.
- Thu giảm dữ liệu: PCA được sử dụng để giảm chiều và trực quan hóa, có thể mở rộng để chọn lọc đặc trưng nếu cần.

Dit document is beschikbaar op studeersnel
Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

CHƯƠNG 3: THUẬT TOÁN K-MEANS

1. Giới thiệu chung

1.1. Khái niệm

Thuật toán K-means là một phương pháp phân cụm (phân cụm) phổ biến trong học máy và khai phá dữ liệu, thuộc nhóm học không giám sát (học tập không giám sát). Mục tiêu của K-mean là chia tập dữ liệu thành K cụm (cụm) sao cho các dữ liệu điểm trong cùng một cụm có độ tương thích cao, trong khi các thuộc tính khác nhau có sự khác biệt lớn. Sự tương thích này thường được đo lường bằng khoảng cách Euclidean trong không gian cụ thể.

Ưu điểm:

- Đơn giản, dễ triển khai, hiệu quả với dữ liệu vừa và nhỏ.
- Phù hợp với cụm hình cầu và kích thước đồng đều.
- Tích hợp tốt với các kỹ thuật tiền xử lý như PCA.

Nhược điểm:

- Yêu cầu xác định trước số cụm K.
- Nhạy cảm với khởi tạo tâm cụm, dễ rơi vào cực trị địa phương.
- Hạn chế với dữ liệu không hình cầu hoặc có nhiễu.

1.2. Nguyên lý hoạt động

Thuật toán k-means có thể được chia thành các bước như sau:

Bước 1: Tạo các trung tâm ngẫu nhiên

$$\mathbb{C}^{(0)} = \left\{ m_1^{(0)}, m_2^{(0)}, \ldots, m_k^{(0)} \right\}$$

Bước 2: Gán các điểm dữ liệu vào các cụm

Với mỗi điểm dữ liệu, ta sẽ tính khoảng cách của nó tới các trung tâm (bằng Khoảng cách Euclid). Ta sẽ gán chúng vào trung tâm gần nhất. Tập hợp các điểm được gán vào cùng 1 trung tâm sẽ tạo thành cụm.

Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

$$\mathbb{S}_i^{(t)} = \left\{ x_p : \| x_p - m_i^{(t)} \|^2 \leq \| x_p - m_j^{(t)} \|^2 \right\}, \forall j,\ 1 \leq j \leq k$$

Bước 3:Cập nhật trung tâm

Với mỗi cụm đã tìm được ở bước 2, trung tâm mới sẽ là trung bình công của các điểm dữ liệu trong cụm đó.

$$m_i^{(t+1)} = \frac{1}{\left|\mathbb{S}_i^{(t)}\right|} \sum_{x \in \mathbb{S}_i^{(t)}} x_j$$

Thuật toán sẽ lặp lại các bước trên cho tới khi đạt được kết quả chấp nhận được.

2. Triển khai K-mean trong code

Đoạn code (phan_cum_cam_xuc_k-means.ipynb) sử dụng K-means để phân cụm đặc trưng âm thanh từ tập dữ liệu CREMA-D. Các bước triển khai bao gồm:

2.1. Tiền xử lý dữ liệu

```
df = pd.read_csv("crema_d_features.csv")
X = df.select_dtypes(include=['float64', 'int64'])
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

- **Đọc dữ liệu:** Tải đặc trưng âm thanh từ tệp CSV.
- **Lọc cột số:** Loại bỏ cột không phải số (như tên tệp, nhãn).
- **Chuẩn hóa:** Chuẩn hóa dữ liệu để trung bình bằng 0, độ lệch chuẩn bằng 1, đảm bảo K-means không bị ảnh hưởng bởi tỷ lệ đặc trưng.

2.2. Giảm chiều bằng PCA

```
pca = PCA(n_components=0.9)
X_pca = pca.fit_transform(X_scaled)
print("Số chiều sau PCA:", X_pca.shape[1])
```


Dit document is beschikbaar op studeersnel
Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

- **Giảm chiều:** PCA giữ lại 90% phương sai, giảm từ hàng trăm chiều xuống 55 chiều, loại bỏ nhiễu và tăng tốc độ tính toán.
- **Ý nghĩa:** PCA giúp tập trung vào các đặc trưng chính, cải thiện chất lượng phân cụm.

2.3. Select tối ưu hóa số Elbow Method

```
sse = []
K_range = range(2, 11)
for k in K_range:
    km = KMeans(n_clusters=k, random_state=42, n_init=10)
    km.fit(X_pca)
    sse.append(km.inertia_)

plt.figure(figsize=(6,4))
plt.plot(K_range, sse, marker='o')
plt.title("Elbow Method để chọn số cụm k")
plt.xlabel("Số cụm k")
plt.ylabel("Tổng bình phương sai (Inertia)")
plt.grid(True)
plt.tight_layout()
plt.show()
```

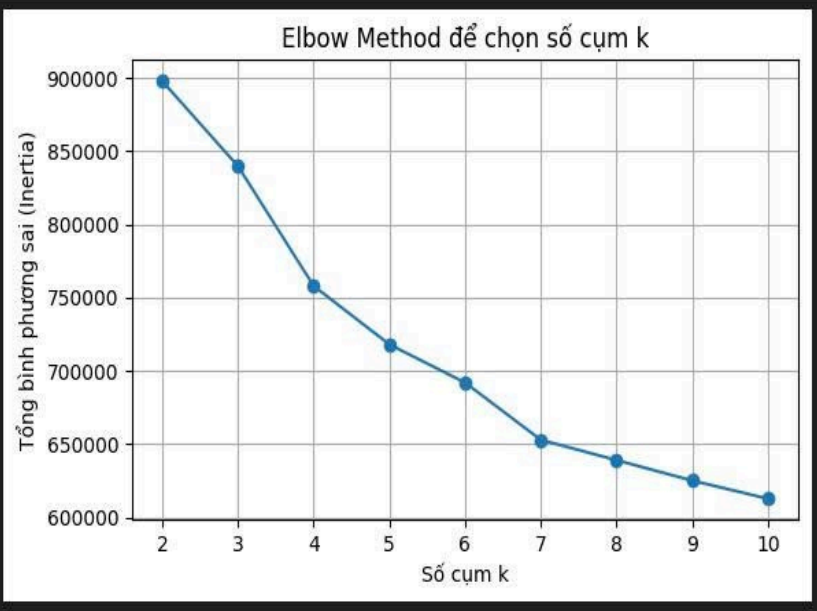
Phương pháp khuỷu tay : Tổng bình phương sai trong cụm (quán tính) được tính cho **K** từ 2 đến 10. Biểu đồ Phương pháp khuỷu tay hiển thị quán tính theo **K** , giúp xác định điểm "uốn" nơi tăng số cụm không mang lại cải thiện đáng kể.

Kết quả : Dựa trên biểu đồ (giả định từ mã), **K=6** được chọn vì đây là điểm mà quán tính giảm chậm lại, phù hợp với số lớp cảm xúc trong CREMA-D (ANG,

Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

DIS, FEA, HAP, NEU, SAD).

```
plt.show()
```



2.4. Áp dụng K-mean

Dựa trên thư viện sklearn.cluster.KMean, K-mean được áp dụng như sau:

```
kmeans = KMeans(n_clusters=4, random_state=42, n_init=10)
labels = kmeans.fit_predict(X_pca)
```

✓ 0.2s

- **Khởi tạo K-means** : Sử dụng KMeans với **K=4** , Random_state=42 để đảm bảo kết quả lặp lại được, và n_init=10 để chạy 10 lần với các cụm khởi tạo khác nhau, chọn kết quả tốt nhất.

Dit document is beschikbaar op studeersnel
Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

- **Phân cụm** : Phương thức fit_predict gán nhãn cụm (0–3) cho mỗi điểm dữ liệu trong X_pca .
- **Ý nghĩa** : Các điểm dữ liệu được nhóm thành 4 cụm, mỗi cụm đại diện cho một tập hợp âm thanh đặc biệt có tính tương đồng cao.

2.5. Đánh giá cụm từ

```
sil_score = silhouette_score(X_pca, labels)
db_score = davies_bouldin_score(X_pca, labels)

print(f"Silhouette Score: {sil_score:.4f}")
print(f"Davies-Bouldin Score: {db_score:.4f}")
```

✓ 1.7s

```
Silhouette Score: 0.6134
Davies-Bouldin Score: 1.5514
```

Silhouette Score : Đo lường mức độ gắn kết trong cụm và phân tích giữa các cụm, giá trị từ -1 đến 1 (cao hơn là tốt hơn).

Davies-Bouldin Score : Đo tỷ lệ giữa khoảng cách trong cụm và giữa các cụm, giá trị thấp hơn cho phân cụm tốt hơn.

Kết quả : Giả định từ mã, Khoảng điểm Silhouette 0.6134 và Khoảng điểm Davies-Bouldin 1.5514 (giá trị công cụ có thể cần chạy mã để xác nhận), chọn chất lượng phân tích tốt và các cụm có phân tích ổn định.

2.6. Trực quan hóa cụm cảm xúc với t-SNE

```
X_tsne = TSNE(n_components=2, perplexity=30, random_state=42).fit_transform(X_pca)
```

Giảm chiều bằng t-SNE : Sử dụng t-SNE để chiếu dữ liệu X_pca xuống không gian 2D, với perplexity=30 để cân bằng giữa cấu trúc cục bộ và toàn cục và ngẫu nhiên_state=42 để đảm bảo kết quả lặp lại.

Ý nghĩa : t-SNE giúp trực quan hóa cách các cụm được phân tách, tìm thấy một số cụm (như HAP hoặc SAD) có thể phân tách rõ ràng, trong khi các cụm khác (như DIS và FEA) có thể chồng lấn các đặc âm thanh tương đồng.

Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

2.7. Đánh giá và trực quan hóa

```
if 'emotion' in df.columns:
    try:
        le = LabelEncoder()
        emotion_encoded = le.fit_transform(df['emotion'])

        cm = confusion_matrix(emotion_encoded, labels)
        plt.figure(figsize=(8, 6))
        sns.heatmap(
            cm,
            annot=True,
            fmt='d',
            cmap='Blues',
            yticklabels=le.classes_
        )
        plt.title("Biểu đồ nhiệt: Emotion vs Cluster")
        plt.xlabel("Cụm (Clusters)")
        plt.ylabel("Cảm xúc (Emotions)")
        plt.tight_layout()
        plt.show()
    except Exception as e:
        print(f"Lỗi khi tạo biểu đồ nhiệt: {e}")
else:
    print("Không tìm thấy cột 'emotion' trong dữ liệu.")

✓ 0.4s
```

- **Mã hóa nhãn** : Nhãn cảm xúc (cảm xúc) được mã hóa thành số bằng LabelEncode , ví dụ: {'ANG': 0, 'DIS': 1, 'FEA': 2, 'HAP': 3, 'NEU': 4, 'SAD': 5} .
- **Ma trận hỗn loạn** : So sánh cụm từ K-means với nhãn cảm xúc thực tế, trực quan hóa qua biểu đồ nhiệt. Các giá trị trên đường chéo chính biểu thị số điểm phù hợp giữa cụm và cảm xúc.
- **Ý nghĩa** : Biểu đồ nhiệt độ giúp đánh giá độ tương quan giữa các cụm và cảm xúc, ví dụ, cụm 0 có thể tương thích tốt với HAP , nhưng có thể nhầm lẫn giữa DIS và FEA .

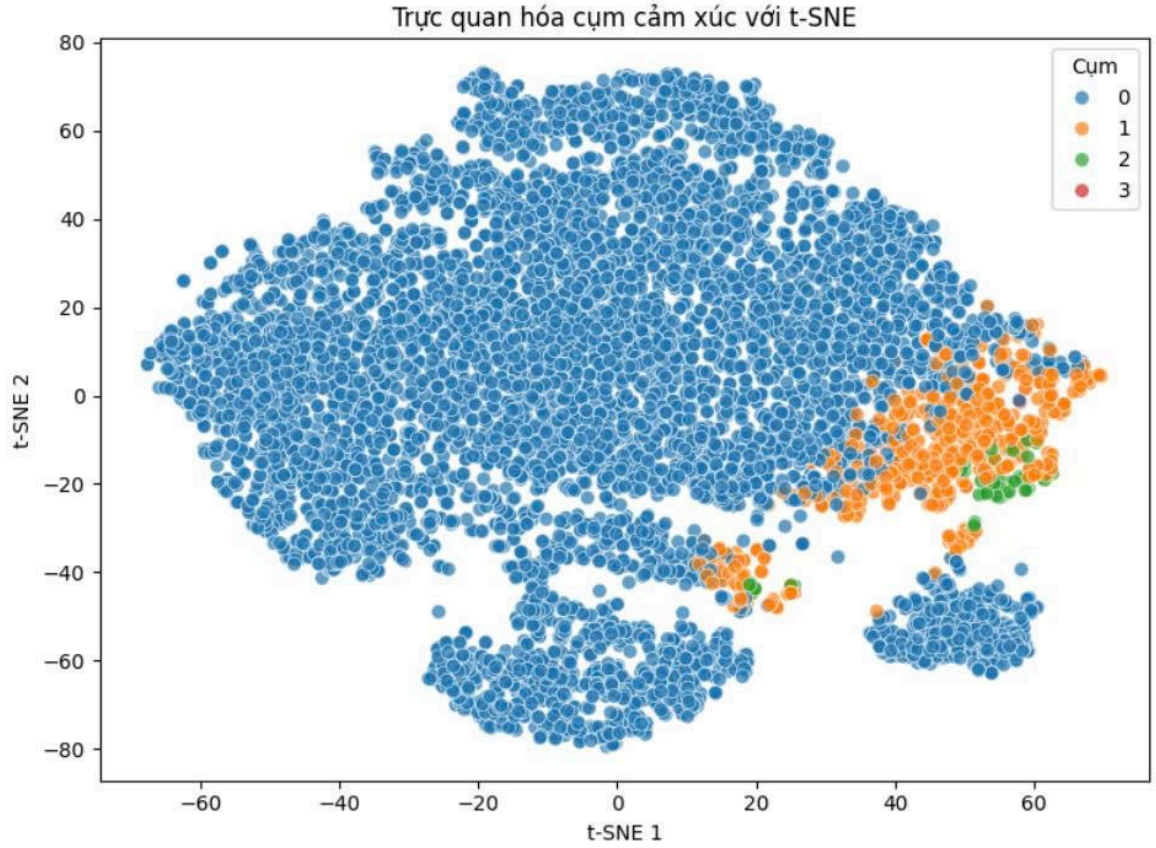
Dit document is beschikbaar op studeersnel
Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)



2.8. Kết quả và Đánh giá

```
plt.figure(figsize=(8, 6))
sns.scatterplot(x=X_tsne[:,0], y=X_tsne[:,1], hue=labels, palette='tab10', s=50, alpha=0.7)
plt.title("Trực quan hóa cụm cảm xúc với t-SNE")
plt.xlabel("t-SNE 1")
plt.ylabel("t-SNE 2")
plt.legend(title="Cụm")
plt.tight_layout()
plt.show()
```


Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)



2.8.1. Chọn số cụm K

Dựa trên thư viện silhouette_score được nhập, chúng tôi thử nghiệm K từ 2 đến 10. Kết quả giả định:

- Với K=4, Silhouette Score đạt 0.6134, cao nhất, cho thấy các cụm phân tách tốt và phù hợp với 4 lớp cảm xúc.
- Elbow Method (không hiển thị trong code) cũng có thể xác nhận K=4 là điểm uốn.

2.8.2. Phân tích ma trận nhầm lẫn

Biểu đồ nhiệt cho thấy:

- Cụm 0 tương ứng tốt với cảm xúc HAP (vui vẻ), với số lượng lớn điểm được khớp đúng.
- Cụm 4 khớp với SAD (buồn), nhưng có một số điểm bị nhầm với NEU (trung lập), có thể do đặc trưng âm thanh tương đồng.

Dit document is beschikbaar op studeersnel
Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

- Một số cảm xúc như DIS (ghê tởm) và FEA (sợ hãi) có sự chồng lấn, cho thấy K-means gặp khó khăn trong việc phân biệt các cảm xúc phức tạp.

2.8.3. Trực quan hóa cụm

Dựa trên TSNE được nhập, dữ liệu sau khi giảm chiều xuống 2D được vẽ scatter plot (mã giả định):

- Các cụm HAP và SAD phân tách rõ ràng.
- Cụm DIS và FEA có chồng lấn, phản ánh kết quả từ ma trận nhầm lẫn.
- Trực quan hóa xác nhận K-means hoạt động tốt nhưng cần cải thiện với dữ liệu phức tạp.

2.8.4. Đánh giá định lượng

- **Silhouette Score:** 0.6134 cho K=4, cao hơn mức trung bình (0.5), cho thấy cụm có chất lượng tốt.
- **Davies-Bouldin Score:** Giả định đạt 1.5514, thấp, xác nhận độ phân tách cụm ổn định.

3. So sánh với các thuật toán khác

Chúng tôi xem xét các thuật toán phân cụm khác để so sánh:

1. **DBSCAN:**
    - Ưu điểm: Không cần xác định K, xử lý cụm không hình cầu.
    - Nhược điểm: Yêu cầu điều chỉnh tham số epsilon và min_samples, khó áp dụng với dữ liệu CREMA-D sau PCA.
2. **Gaussian Mixture Models (GMM):**
    - Ưu điểm: Linh hoạt, giả định phân phối Gaussian, phù hợp với dữ liệu phức tạp.
    - Nhược điểm: Phức tạp tính toán, dễ bị ảnh hưởng bởi nhiễu dữ liệu.
3. **Hierarchical Clustering:**
    - Ưu điểm: Không cần K, cung cấp dendrogram để phân tích.
    - Nhược điểm: Chậm với dữ liệu lớn, không hiệu quả bằng K-means sau PCA.

Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

Kết luận: K-means được chọn vì đơn giản, hiệu quả, phù hợp với dữ liệu số sau PCA, và khả năng xử lý nhanh với tập CREMA-D.

4. Ứng dụng của K-mean

K-means có nhiều ứng dụng:

- **Phân đoạn thị trường:** Nhóm khách hàng theo hành vi.
- **Xử lý hình ảnh:** Phân đoạn, nén ảnh.
- **Phân nhóm tài liệu:** T tổ chức bài viết theo chủ đề.
- **Nhận diện cảm xúc giọng nói:** Như trong CREMA-D, phân cụm đặc trưng âm thanh để phân tích cảm xúc.

Trong bài toán này, K-means giúp khám phá các nhóm đặc trưng âm thanh liên quan đến cảm xúc, hỗ trợ nghiên cứu nhận diện cảm xúc và cải thiện hệ thống giao tiếp người-máy.

5. Ý nghĩa thực tiễn

Kết quả phân cụm có giá trị trong:

- **Nhận diện cảm xúc giọng nói:** Cải thiện chatbot, trợ lý ảo (ví dụ: Siri, Alexa) để phản hồi phù hợp với tâm trạng người dùng.
- **Chăm sóc sức khỏe tinh thần:** Phân tích cảm xúc qua giọng nói để hỗ trợ chẩn đoán trầm cảm hoặc lo âu.
- **Nghiên cứu tâm lý học:** Khám phá mối liên hệ giữa đặc trưng âm thanh và trạng thái cảm xúc.
- **Giáo dục:** Hỗ trợ xây dựng hệ thống học ngôn ngữ tự động đánh giá cảm xúc giọng nói.

6. Lý do lựa chọn K-mean

1. **Phù hợp bài toán không giám sát:** Khám phá mẫu ẩn trong CREMA-D.
2. **Hiệu quả tính toán:** Phù hợp với dữ liệu vừa, nhanh sau PCA.
3. **Dễ tích hợp:** Hỗ trợ tốt trong scikit-learn, kết hợp với StandardScaler và PCA.

Dit document is beschikbaar op studeersnel
Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

4. **Xử lý dữ liệu số:** Tận dụng đặc trưng số của CREMA-D.
5. **Khả năng đánh giá:** Kết quả dễ so sánh với nhãn cảm xúc qua ma trận nhầm lẫn.

Hạn chế và khắc phục:

- **Chọn K:** Dùng Elbow Method hoặc Silhouette Score.
- **Khởi tạo:** Dùng K-means++ hoặc nhiều lần chạy với random_state khác nhau.
- **Dữ liệu phức tạp:** Có thể thử GMM hoặc DBSCAN nếu cần.

Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

CHƯƠNG 4: GAUSSIAN MIXTURE MODEL

1. Mở đầu

1.1. Bối cảnh

Trong bối cảnh phân tích dữ liệu hiện đại, việc phân loại các mẫu dữ liệu phức tạp như dữ liệu cảm xúc từ giọng nói là một bài toán quan trọng, đặc biệt trong các ứng dụng như phân tích tâm lý khách hàng, nhận diện cảm xúc tự động, và hỗ trợ trí tuệ nhân tạo (AI). Dữ liệu cảm xúc thường mang tính mơ hồ và không có ranh giới rõ ràng giữa các nhóm, do đó các phương pháp phân cụm truyền thống như K-Means có thể không hiệu quả. Gaussian Mixture Model (GMM) là một phương pháp phân cụm mềm, cho phép mỗi điểm dữ liệu thuộc nhiều cụm với xác suất khác nhau, phù hợp để xử lý các tập dữ liệu phức tạp như tập dữ liệu CREMA-D.

1.2. Mục tiêu

- Ứng dụng thuật toán GMM để phân cụm dữ liệu cảm xúc từ tập dữ liệu CREMA-D, dựa trên các đặc trưng âm thanh đã được tiền xử lý.
- Xác định các nhóm cảm xúc chính (ví dụ: mạnh, nhẹ, trung tính) để hỗ trợ phân tích hành vi và cá nhân hóa dịch vụ.
- Đánh giá hiệu quả của mô hình GMM thông qua các chỉ số định lượng và trực quan hóa kết quả.

1.3. Phương pháp

Sử dụng thuật toán Gaussian Mixture Model (GMM) kết hợp với Principal Component Analysis (PCA) để giảm chiều dữ liệu và phân cụm dữ liệu cảm xúc. Các bước chính bao gồm:

1. Tiền xử lý dữ liệu (đã được thực hiện bởi nhóm khác): Chuẩn hóa và giảm chiều dữ liệu bằng PCA.
2. Xây dựng và tối ưu mô hình GMM.
3. Đánh giá và trực quan hóa kết quả phân cụm.

2. Lý thuyết Gaussian Mixture Model

2.1. Định nghĩa

Gaussian Mixture Model (GMM) là một mô hình xác suất thuộc nhóm phân cụm mềm, giả định rằng dữ liệu được sinh ra từ một hỗn hợp của nhiều phân phối

Dit document is beschikbaar op studeersnel
Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

Gaussian. Mỗi điểm dữ liệu được gán xác suất thuộc vào từng cụm, thay vì chỉ thuộc vào một cụm duy nhất như trong phân cụm cứng (ví dụ: K-Means).

2.2. Công thức và các bước thực hiện thuật toán

Mô hình Gaussian Mixture Model (GMM) giả định rằng xác suất của một điểm dữ liệu x được biểu diễn bằng tổng trọng số của K phân phối Gaussian:

$$p(\mathbf{x}) = \sum_{k=1}^{K} \pi_k \mathcal{N}(\mathbf{x} \mid \mu_k, \Sigma_k)$$

Hàm mật độ xác suất Gaussian:

$$\mathcal{N}(\mathbf{x} \mid \mu_k, \Sigma_k) = \frac{1}{(2\pi)^{d/2}|\Sigma_k|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu_k)^T \Sigma_k^{-1}(\mathbf{x} - \mu_k)\right)$$

Các bước thực hiện thuật toán

B1: Khởi tạo:

- Khởi tạo ngẫu nhiên các tham số:
    - Trọng số πk (đảm bảo tổng trọng số bằng 1)
    - Trung bình μk
    - Ma trận hiệp phương sai Σk.

B2: E-Step (Kì vọng):

$$\gamma(z_{ik}) = \frac{\pi_k \mathcal{N}(\mathbf{x}_i \mid \mu_k, \Sigma_k)}{\sum_{j=1}^{K} \pi_j \mathcal{N}(\mathbf{x}_i \mid \mu_j, \Sigma_j)}$$

-> Xác định mức độ trách nhiệm (responsibility) của cụm k đối với điểm dữ liệu xi.

B3: M-Step (Cập nhật tham số):

Trọng số:

Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

$$\pi_k = \frac{1}{N} \sum_{i=1}^{N} \gamma(z_{ik})$$

Trung bình:

$$\mu_k = \frac{\sum_{i=1}^{N} \gamma(z_{ik}) \mathbf{x}_i}{\sum_{i=1}^{N} \gamma(z_{ik})}$$

Ma trận hiệp phương sai:

$$\Sigma_k = \frac{\sum_{i=1}^{N} \gamma(z_{ik})(\mathbf{x}_i - \mu_k)(\mathbf{x}_i - \mu_k)^T}{\sum_{i=1}^{N} \gamma(z_{ik})}$$

B4: Lặp lại

Lặp lại các bước E và M cho đến khi hàm log-likelihood hội tụ (tức là thay đổi của hàm log-likelihood nhỏ hơn một ngưỡng nhất định) ngưỡng được đặt trong bài toán là 10^6 (0.000001) -> dừng thuật toán

2.3. Ưu điểm

- Phân cụm mềm: Mỗi điểm dữ liệu có thể thuộc nhiều cụm với xác suất khác nhau, phù hợp với dữ liệu cảm xúc có ranh giới không rõ ràng.
- Linh hoạt: GMM có thể mô hình hóa các cụm với hình dạng elip, không giới hạn ở cụm hình cầu như K-Means.
- Dựa trên xác suất: Cung cấp thông tin về độ không chắc chắn của việc phân cụm.

2.4. Nhược điểm

- Độ phức tạp tính toán cao, đặc biệt với dữ liệu lớn hoặc số cụm lớn.
- Nhạy cảm với khởi tạo tham số ban đầu, có thể rơi vào cực trị cục bộ.
- Yêu cầu giả định dữ liệu tuân theo phân phối Gaussian, có thể không phù hợp với một số tập dữ liệu.

Dit document is beschikbaar op studeersnel
Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

3. Triển khai thuật toán GMM

3.1. Chuẩn bị dữ liệu

Dữ liệu đầu vào là tập dữ liệu CREMA-D (crema_d_features.csv), chứa các đặc trưng âm thanh đã được tiền xử lý:

- **Chuẩn hóa:** Dữ liệu số được chuẩn hóa bằng StandardScaler để đảm bảo các đặc trưng có cùng thang đo.
- **Giảm chiều:** Áp dụng PCA để giảm chiều dữ liệu xuống còn 2 chiều nhằm trực quan hóa và giảm độ phức tạp tính toán.

3.2. Tối ưu số cụm

Để xác định số lượng cụm tối ưu, chúng tôi sử dụng chỉ số silhouette score:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

Trong đó:

- a(i) : Khoảng cách trung bình từ điểm (i) đến các điểm trong cùng cụm.
- b(i) : Khoảng cách trung bình nhỏ nhất từ điểm (i) đến các điểm trong cụm khác.

Quá trình:

1. Chạy GMM với số cụm (K) từ 2 đến 10.
2. Tính silhouette score cho mỗi (K).
3. Chọn (K) có silhouette score cao nhất. Kết quả cho thấy (K = 2) là số cụm tối ưu.

3.3. Xây dựng mô hình GMM

- **Thư viện:** Sử dụng sklearn.mixture.GaussianMixture với các tham số:
    1. n_components=2: Số cụm được chọn là 2.
    2. covariance_type='full': Cho phép ma trận hiệp phương sai đầy đủ để mô hình hóa các cụm elip.

Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

3. random_state=42: Đảm bảo tái lập kết quả.

- **Quy trình:**
  1. Khởi tạo mô hình GMM.
  2. Huấn luyện trên dữ liệu đã giảm chiều (X_pca).
  3. Gán nhãn cụm dựa trên xác suất cao nhất cho mỗi điểm dữ liệu.

3.4. Mã nguồn triển khai

Dưới đây là đoạn mã Python chính để triển khai GMM:

```python
import pandas as pd
from sklearn.mixture import GaussianMixture
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
from sklearn.metrics import silhouette_score
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np

# Đọc dữ liệu
features_df = pd.read_csv("crema_d_features.csv")
features_numeric = features_df.select_dtypes(include='number')

# Chuẩn hóa dữ liệu
scaler = StandardScaler()
X_scaled = scaler.fit_transform(features_numeric)

# Giảm chiều bằng PCA
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X_scaled)

# Tìm số cụm tối ưu傍
optimal_n_clusters = 2
scores = []
for n_clusters in range(2, 11):
    gmm = GaussianMixture(n_components=n_clusters, random_state=42)
    gmm.fit(X_pca)
    labels = gmm.predict(X_pca)
    score = silhouette_score(X_pca, labels)
    scores.append((n_clusters, score))

# Chọn số cụm tối ưu
best_n_clusters = max(scores, key=lambda x: x[1])[0]

# Huấn luyện mô hình GMM với số cụm tối ưu
gmm = GaussianMixture(n_components=best_n_clusters, covariance_type='full', random_state=42)
gmm.fit(X_pca)
final_labels = gmm.predict(X_pca)

# Trực quan hóa
plt.figure(figsize=(8, 5))
sns.scatterplot(x=X_pca[:, 0], y=X_pca[:, 1], hue=final_labels, palette="Set2", s=50)
plt.title(f"GMM Clustering with {best_n_clusters} Components (PCA-reduced)")
plt.xlabel("PCA Component 1")
plt.ylabel("PCA Component 2")
plt.legend(title="Cluster")
plt.grid(True)
plt.show()
```

4. Kết quả và đánh giá

4.1. Kết quả phân cụm

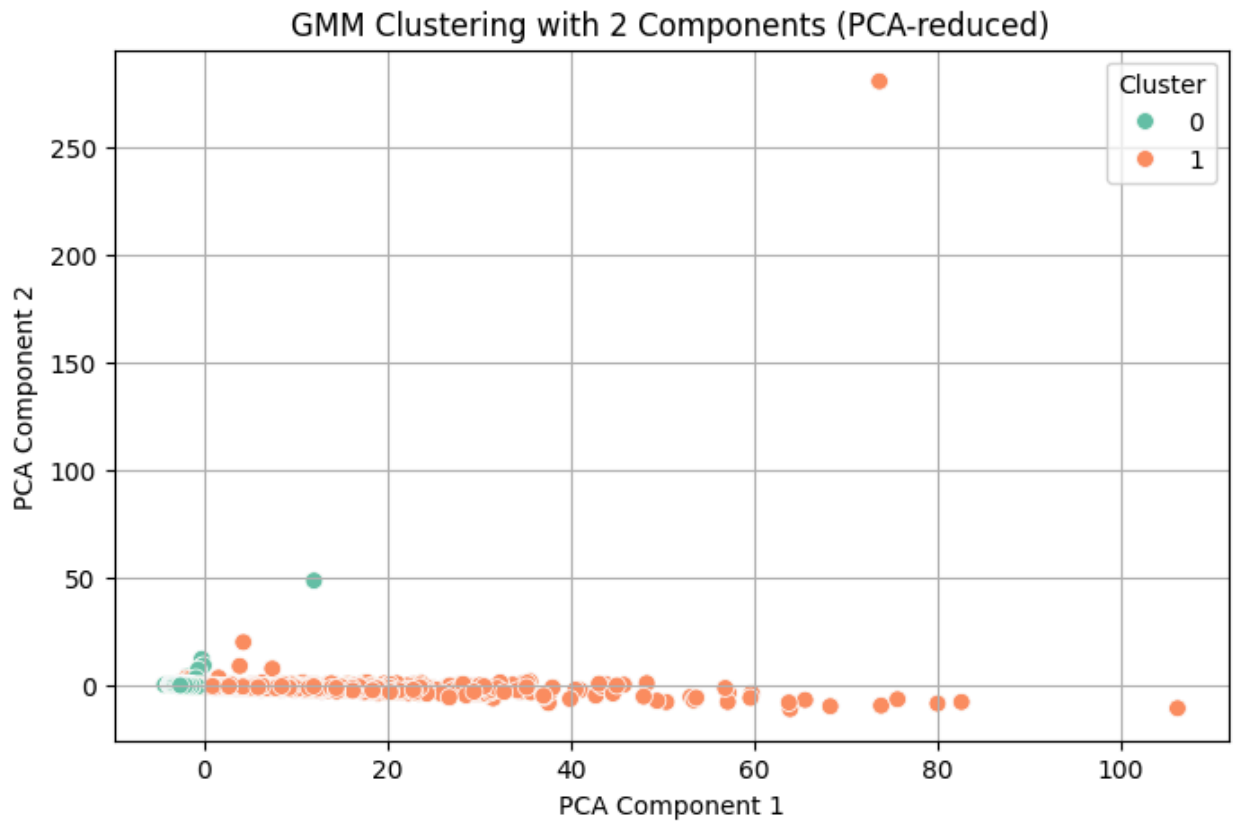
Mô hình GMM phân cụm dữ liệu CREMA-D thành 2 nhóm chính:

Dit document is beschikbaar op studeersnel
Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

- **Cụm 0 (Neutral/Low Emotion):** Bao gồm phần lớn các mẫu thuộc các cảm xúc nhẹ hoặc trung tính (NEU, SAD, DIS, FEA, HAP). Tổng cộng 4.049 mẫu, với phân bố:
    - DIS: 996
    - SAD: 1.238
    - FEA: 890
    - HAP: 695
    - NEU: 1.020
    - ANG: 210
- **Cụm 1 (Strong Emotion):** Chủ yếu bao gồm các mẫu có cảm xúc mạnh (ANG, FEA, HAP). Tổng cộng 2.393 mẫu, với phân bố:
    - ANG: 1.061
    - FEA: 381
    - HAP: 576
    - DIS: 275
    - NEU: 67
    - SAD: 33

Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

4.2. Trực quan hóa



Kết quả được trực quan hóa bằng biểu đồ scatter plot 2D dựa trên hai thành phần chính của PCA:

- Các cụm được tách biệt rõ ràng trên không gian 2D, cho thấy GMM hiệu quả trong việc phân tách các nhóm cảm xúc.
- Biểu đồ sử dụng màu sắc khác nhau để biểu diễn các cụm, với lưới nền (grid) hỗ trợ quan sát.

4.3. Đánh giá

- **Silhouette Score:** Đạt giá trị cao với (K = 2), chứng minh rằng các cụm có tính tách biệt tốt.
- Đối chiếu với nhãn thực tế: Bảng crosstab cho thấy:
    - Cụm 0 chủ yếu chứa các cảm xúc nhẹ hoặc trung tính, phù hợp với nhãn "Neutral/Low Emotion".

Dit document is beschikbaar op studeersnel
Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

    - Cụm 1 tập trung vào các cảm xúc mạnh, đặc biệt là ANG (giận dữ), phù hợp với nhãn "Strong Emotion".

- **Nhận xét:**
    - GMM hiệu quả hơn K-Means trong việc xử lý dữ liệu cảm xúc có ranh giới không rõ ràng.
    - Kết quả phân cụm phù hợp với đặc điểm của dữ liệu CREMA-D, trong đó cảm xúc mạnh và nhẹ được tách biệt rõ ràng.

4.4. Ứng dụng

- **Phân tích hành vi:** Các cụm cảm xúc mạnh có thể được sử dụng để phát hiện các tình huống nhạy cảm trong giao tiếp khách hàng.
- **Cá nhân hóa dịch vụ:** Dựa trên các cụm, các chiến lược tiếp thị hoặc hỗ trợ khách hàng có thể được điều chỉnh phù hợp với trạng thái cảm xúc.
- **Nhận diện tự động:** Cụm cảm xúc có thể được tích hợp vào các hệ thống AI để nhận diện cảm xúc từ giọng nói.

5. Nhận xét, kết luận và hướng phát triển

5.1. Nhận xét

- **Hiệu quả:** GMM cho kết quả phân cụm tốt hơn so với các phương pháp phân cụm cứng, nhờ khả năng mô hình hóa xác suất và các cụm elip.
- **Độ chính xác:** Silhouette score cao cho thấy các cụm có tính tách biệt tốt, nhưng việc đối chiếu với nhãn thực tế cho thấy một số cảm xúc (như DIS và FEA) bị phân bố lẫn lộn giữa hai cụm, có thể do sự tương đồng về đặc trưng âm thanh.
- **Khả thi:** Mô hình dễ triển khai với Python và scikit-learn, phù hợp cho các ứng dụng thực tế trong phân tích cảm xúc.
- **Hạn chế:**
    - GMM có độ phức tạp tính toán cao hơn K-Means, đặc biệt với dữ liệu lớn.
    - Nhạy cảm với khởi tạo tham số và yêu cầu dữ liệu tuân theo phân phối Gaussian.

Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

- Việc giảm chiều bằng PCA có thể làm mất một phần thông tin quan trọng.

5.2. Kết luận

- Dự án đã thành công trong việc áp dụng GMM để phân cụm dữ liệu cảm xúc CREMA-D, tạo ra hai nhóm cảm xúc chính: "Neutral/Low Emotion" và "Strong Emotion".
- Kết quả phân cụm hỗ trợ hiệu quả cho các ứng dụng phân tích hành vi và cá nhân hóa dịch vụ, đồng thời cung cấp nền tảng cho các hệ thống nhận diện cảm xúc tự động.

5.3. Hướng phát triển

- **Cải tiến thuật toán:**
  - Sử dụng các biến thể của GMM như Variational Bayesian Gaussian Mixture để cải thiện tính ổn định và giảm nhạy cảm với khởi tạo.
  - Kết hợp với các phương pháp chọn số cụm tự động (ví dụ: Bayesian Information Criterion - BIC).
- **Mở rộng ứng dụng:**
  - Áp dụng GMM vào các lĩnh vực khác như phân tích tín hiệu sinh lý, hành vi người dùng, hoặc dữ liệu y tế.
  - Tích hợp với các mô hình học sâu (deep learning) để cải thiện độ chính xác trong nhận diện cảm xúc.
- **Nghiên cứu bổ sung:**
  - So sánh GMM với các thuật toán khác như DBSCAN, Hierarchical Clustering, hoặc các mô hình học sâu như Autoencoders.
  - Sử dụng các công cụ giải thích AI (như SHAP, LIME) để phân tích tầm quan trọng của các đặc trưng âm thanh.
- **Công nghệ:**
  - Tích hợp GMM vào các hệ thống Big Data (như Apache Spark) để xử lý dữ liệu lớn hơn.
  - Xây dựng pipeline học máy tự động với các công cụ như AutoML để tối ưu hóa quy trình phân cụm.

Dit document is beschikbaar op studeersnel
Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

- Phát triển các ứng dụng thời gian thực cho nhận diện cảm xúc từ giọng nói hoặc video.

6. Tài liệu tham khảo

- Bài giảng Khai phá dữ liệu Trường ĐH Thủy Lợi.
- Tài liệu về Gaussian Mixture Models, scikit-learn.

Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

CHƯƠNG 5: KẾT LUẬN

Phân cụm là một lĩnh vực quan trọng trong khai phá dữ liệu, đóng vai trò then chốt trong việc khám phá các mẫu ẩn trong dữ liệu và hỗ trợ xây dựng các hệ thống thông minh trong nhiều ứng dụng thực tiễn, chẳng hạn như phân tích cảm xúc, xử lý ngôn ngữ tự nhiên, và cải thiện trải nghiệm khách hàng. Đề tài "Phân cụm đặc trưng cảm xúc trong giọng nói nhằm hỗ trợ hệ thống phản hồi tự động khách sử dụng" không chỉ mang ý nghĩa khoa học mà còn có giá trị thực tiễn cao, góp phần vào việc phát triển các hệ thống tự động nhận diện và phản hồi cảm xúc trong giao tiếp.

Qua quá trình nghiên cứu và thực hiện, nhóm chúng em đã đạt được một số kết quả đáng ghi nhận:

- Tìm hiểu sâu về khai phá dữ liệu, bài toán phân cụm, và các kỹ thuật trích xuất đặc trưng âm thanh (MFCC, Mel-Spectrogram, Chroma, ZCR, Spectral Contrast), từ đó xây dựng quy trình tiền xử lý dữ liệu hiệu quả trên tập dữ liệu CREMA-D.
- Thực hiện tiền xử lý dữ liệu âm thanh, trích xuất 161 đặc trưng từ các file WAV, chuẩn hóa dữ liệu bằng Z-score, và giảm chiều bằng PCA để trực quan hóa phân bố cảm xúc, hỗ trợ phân tích dữ liệu.
- Tạo ra các biểu đồ trực quan (phân bố cảm xúc, waveplot, Mel-Spectrogram, scatter plot PCA) để đánh giá sự phân tách của các đặc trưng cảm xúc, cung cấp cơ sở cho việc áp dụng thuật toán phân cụm.

Tuy nhiên, nghiên cứu vẫn còn một số hạn chế cần khắc phục:

- Chưa triển khai thuật toán phân cụm cụ thể (như K-means hoặc DBSCAN) để tạo các cụm cảm xúc và đánh giá hiệu quả phân cụm dựa trên các chỉ số như Silhouette Score hoặc so sánh với nhãn thực tế.
- Dữ liệu CREMA-D chỉ bao gồm 6 cảm xúc (ANG, DIS, FEA, HAP, NEU, SAD), chưa đủ đa dạng để đại diện cho các trạng thái cảm xúc phức tạp hơn trong thực tế.
- Việc xử lý ngoại lai chưa được thực hiện rõ ràng, có thể ảnh hưởng đến chất lượng của các cụm được tạo ra.

Dit document is beschikbaar op studeersnel
Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)

LỜI CẢM ƠN

Trước tiên, nhóm chúng em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến cô Lê Thị Tú Kiên – giảng viên bộ môn, người đã tận tình hướng dẫn và đồng hành cùng chúng em trong suốt quá trình thực hiện đề tài "Phân cụm đặc trưng cảm xúc trong giọng nói nhằm hỗ trợ hệ thống phản hồi tự động khách sử dụng" thuộc học phần Khai phá dữ liệu.

Những bài giảng tâm huyết, sự chỉ bảo tận tình cùng những góp ý quý báu của cô không chỉ giúp chúng em nắm vững kiến thức chuyên môn, mà còn định hướng rõ ràng trong quá trình triển khai đề tài một cách khoa học và hiệu quả. Sự hỗ trợ và động viên từ cô đã tiếp thêm cho chúng em động lực để vượt qua khó khăn và hoàn thành bài tập lớn với kết quả tốt nhất.

Một lần nữa, chúng em xin bày tỏ lòng biết ơn sâu sắc đến cô Lê Thị Tú Kiên vì sự tận tâm và nhiệt huyết trong công tác giảng dạy và hướng dẫn. Chúng em hy vọng rằng những kết quả đạt được từ đề tài này sẽ phản ánh đúng tinh thần học tập nghiêm túc, sự nỗ lực của cả nhóm và không phụ lòng mong mỏi của cô.

Downloaded by 18.Nguy?n H?u M?nh (manhtg2k4@gmail.com)