# Phần 4.1:

Đến với phần quan trọng nhất là xử lý văn bản. Đầu tiên, chúng ta có phương pháp cơ bản nhất gọi là **Bag of Words**.

Các bạn cứ tưởng tượng máy tính sẽ cầm một cái túi, nó nhặt hết các từ trong văn bản bỏ vào túi và lắc đều lên. Nó không cần biết ngữ pháp đúng sai thế nào, nó chỉ đếm xem từ 'AI' xuất hiện mấy lần, từ 'học' xuất hiện mấy lần.

Scikit-learn thực hiện việc này qua 3 bước: Cắt từ, Lập từ điển và Đếm. Kết quả là ta có được một vector số đơn giản đại diện cho văn bản đó.

# Phần 4.2:

Tuy nhiên, đếm từ thôi thì chưa đủ. Trong tiếng Việt, từ 'là' xuất hiện ở khắp mọi nơi. Nếu chỉ đếm, máy sẽ tưởng từ 'là' là từ khóa quan trọng nhất. Điều này sai hoàn toàn.

Để khắc phục, chúng ta dùng kỹ thuật nâng cao hơn là **TF-IDF**. > Điểm hay nhất của kỹ thuật này nằm ở chỉ số **IDF**. Nó hoạt động như một bộ lọc thông minh: Nếu một từ xuất hiện ở tất cả các văn bản, nó sẽ bị coi là từ phổ thông và bị gán điểm thấp. Ngược lại, những từ hiếm như 'Machine Learning' sẽ được gán trọng số rất cao.

Đây chính là thuật toán nền tảng giúp Google biết được nội dung chính của một trang web là gì.

# Phần 5:

Chúng ta chuyển sang phần xử lý Hình ảnh. Các bạn có bao giờ thắc mắc tại sao máy tính nhận diện được khuôn mặt không?

Thực tế, máy tính không có mắt. Nó 'nhìn' bức ảnh dưới dạng một **Tensor 3D** - tức là một khối ma trận 3 chiều khổng lồ chứa hàng triệu con số đại diện cho màu sắc.

Để xử lý khối dữ liệu này, Scikit-learn sử dụng kỹ thuật gọi là **Patch Extraction** (Trích xuất mảnh). Thay vì cố gắng 'tiêu hóa' cả bức ảnh lớn một lúc, thuật toán sẽ cắt bức ảnh ra thành hàng nghìn mảnh nhỏ (patches).

Tại sao phải làm vậy? Vì các đặc điểm quan trọng như: con mắt, cái mũi, hay mép bàn... đều là những **đặc trưng cục bộ (Local Features)**. Việc cắt nhỏ giúp máy tính tập trung phân tích chi tiết từng đường nét, góc cạnh, từ đó mới ghép lại để nhận diện vật thể. Dù ngày nay AI đã phát triển rất mạnh, nhưng tư duy 'chia nhỏ để trị' này vẫn là nền tảng cốt lõi.

# Phần 6:

Để khép lại bài báo cáo, mình xin tổng kết lại toàn bộ kiến thức qua bảng so sánh trên slide.

Trong thực tế làm việc, các bạn chỉ cần nhớ quy tắc '4 ngón tay' này:

1. Gặp dữ liệu dạng bảng, danh mục -> Dùng ngay **One-Hot Encoding**.
2. Gặp dữ liệu khổng lồ (Big Data) -> Phải nhớ đến kỹ thuật **Băm (Hashing)** để cứu bộ nhớ RAM.
3. Gặp văn bản -> Chắc chắn phải dùng **TF-IDF** để tìm từ khóa vàng.
4. Và gặp hình ảnh -> Hãy nhớ về ma trận Pixel.

Có một câu nói rất hay trong ngành dữ liệu: **'Dữ liệu thô giống như dầu mỏ, còn Feature Extraction chính là nhà máy lọc dầu.'** Nếu chúng ta không lọc sạch tạp chất, không trích xuất được những gì tinh túy nhất, thì dù thuật toán AI có thông minh đến đâu cũng không thể hoạt động hiệu quả.

Đó cũng là thông điệp cuối cùng mà nhóm mình muốn gửi gắm. Cảm ơn Thầy và các bạn đã chú ý lắng nghe!